

國立陽明交通大學 生物醫學工程學系
National Yang Ming Chiao Tung University
專題成果報告

前處理策略對醫學影像分割效能的影響
-以 SwinUNETR 為例

The Impact of Preprocessing Strategies on Medical Image
Segmentation Performance Using SwinUNETR

學生姓名：徐偉翔 (Wei-Hsiang, Hsu)
指導教授：陳右穎 教授 (Prof. You-Yin, Chen)

中華民國 一一四 年 九 月

目錄

第一章 緒論.....	1
第一節 研究背景.....	1
第二節 研究動機.....	1
第三節 研究目的.....	2
第四節 研究問題與假設.....	2
第二章 研究方法.....	2
第三章 研究結果.....	5
第四章 討論.....	9
第五章 未來展望.....	9
參考文獻.....	11

第一章 緒論

第一節 研究背景

在現代醫學中，臨床診斷與治療規劃已高度依賴斷層影像，而其中最關鍵的莫過於 MRI 與 CT 兩種影像模態。MRI 的優勢在於能藉由氫質子在不同組織中的縱向 (T1) 與橫向 (T2) 訊號恢復特性，呈現出極佳的軟組織對比，對細小結構與病灶邊界特別敏感。相較之下，CT 則是透過 X 光衰減係數成像，能清晰描繪骨性結構與鈣化病灶，並具備快速掃描與高度可近性的優勢 (Johns Hopkins Medicine, n.d.; MD Anderson Cancer Center, 2023; Radiopaedia, 2025)。正因如此，MRI 與 CT 已成為臨床最普及且不可或缺的影像來源，廣泛應用於疾病診斷、治療計畫與預後追蹤。

然而，當這些影像被應用於深度學習分析時，挑戰隨之而來。不同儀器條件、成像機制與病患個體差異，會造成影像在強度分布、解析度與背景訊號上存在不一致性，使模型容易學到偏差特徵。特別是在 CT 影像中，軟組織對比度有限，細微結構與病灶邊界難以精確分辨，若缺乏嚴謹前處理，不僅降低分割可靠性，也可能影響臨床決策的準確性。為了因應這些挑戰，重採樣 (Re-sampling)、正規化 (Normalization)、座標對齊 (Registration) 與前景裁剪 (Foreground Extraction) 等步驟，已被廣泛視為確保效能穩定與結果可重現的關鍵基礎 (Nyúl & Udupa, 1999; Çiçek et al., 2016; Guan & Liu, 2022)。

第二節 研究動機

近年來，深度學習模型的發展為醫學影像分割帶來顯著突破，其中 SwinUNETR 架構結合了 Transformer 的全域特徵建模與 U-Net 解碼器的逐層重建能力，在多項挑戰中展現優異成果 (Hatamizadeh et al., 2022)。然而，越來越多研究指出，前處理與評估方式的選擇，往往對結果的影響不亞於模型本身 (Sudre et al., 2017)。不同策略可能使分割效能被高估或低估，造成跨資料集與跨模態比較的不一致，進而限制了臨床應用的可信度。

在前處理的各個面向中，推論策略與評估設定具有特別關鍵的影響。推論策略決定了模型如何處理輸入影像，影響分割結果的細緻度與一致性；而評估設定則會改變效能指標的計算方式，進而影響結果的解讀與不同方法間的比較。這些因素若缺乏統一規範，可能會成為限制臨床應用的瓶頸。

因此，本研究將聚焦於比較不同的推論策略與評估設定，並分別在 MRI 與 CT 影像上以 SwinUNETR 進行測試。藉由系統性實驗釐清這些選擇對模型效能與結果解讀的影響，期望能凸顯前處理在醫學影像分割任務中的關鍵角色，並為後續臨床應用提供更公平性與參考價值的依據。

第三節 研究目的

本研究旨在探討前處理策略對醫學影像分割效能與結果解讀的影響，以 SwinUNETR 架構作為基礎模型，分別在 MRI 與 CT 兩種模態下進行實驗，並以 Dice 作為主要量化指標，透過統計分析與圖表方式呈現不同設定下的差異(Hatamizadeh et al., 2022)。由於 MRI 與 CT 在臨床應用上各具優勢，但在自動化分析時仍面臨輸入品質不一致與影像特徵差異等挑戰 (Zhou et al., 2024)，本研究特別著重於兩個核心面向。其一是比較不同的推論策略，藉由 sliding-window 與整圖裁補兩種方式的對照，檢驗輸入方式對分割精度與穩定性的影響；其二則是分析評估設定的差異，透過含背景與不含背景兩種 Dice 分數計算方式，探討其在結果呈現與臨床解讀上的差異(Sudre et al., 2017)。藉由系統性實驗，本研究期望能釐清這些前處理相關選擇如何改變模型效能與統計檢定結果，並凸顯在跨模態比較時建立一致且嚴謹規範的重要性，最終為醫學影像分割研究與臨床應用提供更具公允性與參考價值的依據。

第四節 研究問題與假設

本研究聚焦於前處理策略在醫學影像分割中的影響，特別是推論策略與評估設定兩個面向。首先，我們檢驗推論策略對小結構品質與整體效能的影響(RQ1)。在模型權重與資料保持一致的前提下，僅更換推論方式，比較整圖裁補與 sliding-window (SW) 的結果。考量滑窗推論具備切塊與平滑拼接機制，能減少邊界誤差並較好保留細節，我們預期 sliding-window 在 Dice 分數上表現優於整圖裁補，且差異在 CT 模態中更為顯著，而在 MRI 中則相對有限(H1)。

其次，我們釐清評估設定對數值解讀的影響(RQ2)。研究關注平均指標中是否應排除背景類別，以獲得更公允的跨條件比較。預期在移除背景後，整體 Dice 的數值雖然下降，但更能反映器官與病灶等困難類別的真實表現，因此更適合作為跨模態與跨資料集的比較基準。特別是在 CT 的情境下，由於背景佔比龐大，預期差異將更為顯著，而在 MRI 中則相對有限(H2)。

第二章 研究方法

本研究分別使用一組 MRI 資料集與一組 CT 資料集。MRI 資料集使用網路上公開的資料集 Mendeley Lumbar Spine MRI Dataset (Sudirman et al., 2019)，以 515 位腰痛患者做為樣本數，每位受試者對應多張切片，共計 48,345 影像，照片涵蓋 L3 至 L5、對應椎間盤與薦骨等結構；CT 資料集同樣使用網路上公開的資料集 Kaggle CT Segmentation Dataset (Kaggle, n.d.)，總共收集 1,089 份 CT 掃描做為樣本數，照片涵蓋 C1 至 S1 與相關結構。兩組資料均具專科醫師提供的分割標註，並以固定亂數種子切分為訓練、驗證與測試集，以確保分割任務的可比性與再現性。

模型骨幹均採用 SwinUNETR 架構(圖 1)，其設計結合 Transformer 編碼器與 U-Net 解碼器，適合三維醫學影像分割(Hatamizadeh et al., 2022)。共通設定輸入尺寸為 $128 \times 128 \times 128$ voxel、單通道輸入、特徵維度設定為 48，輸出通道依標註決定，MRI

共 21 類，而 CT 共 26 類。MRI 資料標註中部分類別誤標已於前處理階段修正，以確保標籤一致性。




圖 1. Swin UNETR 架構示意圖。模型結合 Swin Transformer 的全域特徵建模與 U-Net 的編碼 - 解碼架構。輸入影像經切分與嵌入後進入編碼器，透過區域性自注意力學習多尺度特徵；解碼器則結合跳躍連接與上採樣層逐步還原空間解析度，最終輸出三維分割結果。

兩種模態採用完全一致的資料前處理，所有影像與標籤統一轉換為 RAS 座標系。CT 影像在 -170 至 250 HU 範圍內正規化，MRI 影像則 rescale 至 [0,1]。空間解析度重採樣至 (1.5, 1.5, 1.0) mm，並裁剪前景區域以減少冗餘訊號。訓練時額外施加隨機翻轉、90 度旋轉與強度偏移等增強，以提升模型的泛化能力。

在訓練過程中，兩模態皆採用 DiceCELoss 作為損失函數，結合 Dice loss 與 Cross Entropy 以平衡類別不均問題。其數學形式可表達為：

$$\mathcal{L}_{DiceCE} = \alpha \mathcal{L}_{Dice} + \beta \mathcal{L}_{CE} \quad (1)$$

其中，

$$\mathcal{L}_{Dice} = 1 - \frac{1}{C} \sum_{c=0}^{C-1} \frac{2 \sum_{n=1}^B \sum_{i=1}^N p_{n,i,c} g_{n,i,c} + \epsilon}{\sum_{n=1}^B \sum_{i=1}^N p_{n,i,c} + \sum_{n=1}^B \sum_{i=1}^N g_{n,i,c} + \epsilon} \quad (2)$$

$$\mathcal{L}_{CE} = -\frac{1}{BN} \sum_{n=1}^B \sum_{l=1}^N \sum_{c=0}^{C-1} g_{n,l,c} \log p_{n,l,c} \quad (3)$$

符號定義如下： B 為 batch 大小、 N 為每筆樣本的像素/體素數、 C 為類別數(含背景)、 $p_{n,l,c}$ 為 softmax 機率、 $g_{n,l,c}$ 為 one-hot 標籤、 $\epsilon = 10^{-5}$ 為平滑常數、 α 與 β 為加權係數(本研究設定為 1)。

在訓練細節方面，優化器則使用加權衰減隨機梯度下降自適應動量估計 (Adaptive Moment Estimation with Weight Decay, AdamW)，學習率設定為 1×10^{-4} ，並搭配 weight decay = 1×10^{-5} 抑制過擬合。每次訓練以 batch size = 1 進行，總訓練週期為 100 epoch，並於每 5 個 epoch 進行一次驗證。為提高數值穩定性，訓練全程啟用了混合精度訓練 (automatic mixed precision, AMP) 與梯度縮放 (gradient scaling)。

在推論階段，本研究使用已訓練完成的 SwinUNETR 模型參數，並在不計算背景的情況下，以 batch size = 1 進行推論。預設採用 sliding-window 機制，將子區塊重疊率設定為 0.25，以確保大體積影像能分段處理並在重疊區域融合結果，避免因整體縮放而損失細節。模型輸出經 softmax 轉換後生成 one-hot 格式，以利後續計算。

評估指標採用 DiceMetric，將預測與標註經 one-hot 編碼後逐體積比較，最終回傳平均 Dice 作為整體效能指標。此外，為比較差異，本研究進一步採用 Welch 改良式獨立樣本 t 檢定 (Welch, 1947; Satterthwaite, 1946; James, Witten, Hastie, & Tibshirani, 2021)。其數學公式如下：

$$T = \frac{\Delta \bar{X}}{s_{\Delta \bar{X}}} = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} \quad (4)$$

符號定義如下： $\bar{X}_1, \bar{X}_2$ 分別為兩組樣本的平均值、 s_1^2, s_2^2 為兩組樣本的變異數、 n_1, n_2 為兩組樣本的樣本數。

其自由度 (degree of freedom, df) 由 Welch - Satterthwaite 方程式近似 (Satterthwaite, 1946)：

$$df = \frac{(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2})^2}{\frac{(s_1^2/n_1)^2}{n_1 - 1} + \frac{(s_2^2/n_2)^2}{n_2 - 1}} \quad (5)$$

透過此檢定可判斷兩組平均值是否存在統計顯著差異，本研究均採雙尾檢定，顯著水準設為 $\alpha=0.05$ ，並同時回報 p 值與 95% 信賴區間，以增強結果的解釋性。

針對研究問題(RQ1 - RQ2)，本研究分兩個面向進行分析。首先，在推論策略(RQ1)中，比較 sliding-window (滑動視窗) 與整圖裁補兩種方式對分割效能的影響。在保持模型權重與資料一致的前提下，僅更換推論方式，並透過 Welch 改良式獨立樣本 t 檢定比較兩者在 MRI 與 CT 模態下的差異。其次，在評估設定(RQ2)中，針對同一組預測結果，分別計算「含背景」與「不含背景」兩種 Dice 分數，並進行統計檢定，探

討不同評估規則對數值解讀的影響，以及其在跨模態比較中的公允性。為確保結果的嚴謹性與可解釋性，本研究均回報平均值、標準差、p 值與 95% 信賴區間，並輔以圖表呈現差異，以凸顯不同前處理策略在模型效能與結果解讀上的影響。

第三章 研究結果

在推論策略比較的實驗中，本研究同樣針對 MRI 與 CT 測試集，分別採用 sliding-window (SW) 與整圖裁補兩種方式進行推論，並進行了五次隨機抽取，每次取 50 筆資料進行推論與評估，再以獨立樣本 t 檢定比較兩組結果。

結果顯示，MRI 模態在使用 sliding-window 做推論的五次測試分數分別為 0.8024、0.8409、0.7938、0.8334 與 0.7752；使用整圖裁補做推論的五次測試分數分別為 0.7393、0.7621、0.7813、0.7015 與 0.7286（圖 2）。經計算，sliding-window 的平均值為 0.8091（SD=0.0275），整圖裁補的平均值為 0.7426（SD=0.0307）。以 Welch 改良式獨立樣本 t 檢定分析，結果為 $t(7.91) = 3.610$ 、 $p = 0.007$ ，95% CI [0.0240, 0.1092]，顯示差異達統計顯著（圖 3）。




圖 2. MRI 模態在不同推論策略下的五次 Dice 分數比較。折線圖顯示 sliding-window（實線）與整圖裁補（虛線）於五次隨機抽取測試中的分數變化。結果顯示 SW 在各次測試中整體表現優於整圖裁補，顯示其在 MRI 影像分割中能提供較高的穩定性。




圖 3. MRI 模態在不同推論策略下的 Dice 平均分數比較。sliding-window (0.8091 ± 0.0275) 顯著優於整圖裁補 (0.7426 ± 0.0307)，Welch 改良式獨立樣本 t 檢定結果顯示差異達統計顯著 ($t(7.91) = 3.610$ ， $p = 0.007$ ，95% CI [0.0240, 0.1092])。誤差棒表示標準

差，顯著性以 ** 標示。

CT 模態在使用 sliding-window 做推論的五次測試分數分別為 0.6475、0.6033、0.6658、0.6351 與 0.6803，而使用整圖裁補做推論的五次測試分數分別為 0.4634、0.4981、0.4217、0.5129 與 0.4478(圖 4)。經計算，使用 sliding-window 做推論的平均值為 0.6464 (SD=0.0296)，使用整圖裁補的平均值為 0.4688 (SD=0.0371)。以 Welch 改良式獨立樣本 t 檢定分析，結果為 $t(7.63) = 8.371$ 、 $p < 0.001$ ，95% CI [0.1283, 0.2270]，顯示差異呈現高度顯著(圖 5)。




圖 4. CT 模態在不同推論策略下的五次 Dice 分數比較。折線圖顯示 sliding-window(實線)與整圖裁補(虛線)於五次隨機抽取測試中的分數變化。整體趨勢呈現 SW 在各次測試中均高於整圖裁補，顯示其於 CT 影像分割中能更穩定保留細節與邊界資訊。




圖 5. CT 模態在不同推論策略下的 Dice 平均分數比較。sliding-window (0.6464 ± 0.0296)顯著優於整圖裁補(0.4688 ± 0.0371)，Welch 改良式獨立樣本 t 檢定結果顯示差異呈現高度顯著 ($t(7.63) = 8.371$ ， $p < 0.001$ ，95% CI [0.1283, 0.2270])。誤差棒表示標準差，顯著性以 *** 標示。

整體而言，MRI 與 CT 皆呈現 SW 顯著優於整圖裁補的結果，支持研究假設 H1。特別是在 CT 模態中，兩組差異達高度顯著 ($p < 0.001$)，顯示 CT 在影像細節與對比不足時，整圖推論的限制更為明顯，因此更依賴 SW 的區域性處理來維持分割精度。相對之下，MRI 雖然在整圖推論下仍能保持一定水準，但 t 檢定結果亦顯示 SW 的提升

具有統計顯著性 ($p = 0.007$)，說明其優勢一致且穩定。

在評估設定比較的實驗中，本研究於 MRI 與 CT 的測試集各進行五次隨機抽取，每次取 50 筆資料進行推論與評估，並分別計算「不含背景」與「含背景」的整體 Dice 分數，同樣以獨立樣本 t 檢定比較兩組結果。

在 MRI 模態中，不含背景的五次 Dice 分數分別為 0.8051、0.8497、0.7822、0.8024 與 0.7972；含背景則為 0.8205、0.8031、0.8417、0.8159 與 0.8528 (圖 6)。經計算，不含背景的平均值為 0.8073 ($SD = 0.0253$)，含背景的平均值為 0.8268 ($SD = 0.0201$)。以 Welch 改良式獨立樣本 t 檢定分析，結果為 $t(7.61) = -1.348$, $p = 0.216$, 95% CI $[-0.0531, 0.0141]$ ，顯示兩組差異未達統計顯著 (圖 7)。




圖 6. MRI 模態在不同評估設定下的五次 Dice 分數比較。折線圖顯示「不含背景」(實線)與「含背景」(虛線)於五次隨機抽取測試中的分數變化。雖然兩者在數值上略有差異，但整體趨勢顯示兩種設定的變動幅度相近，顯示背景納入與否對 MRI 分割效能影響有限。




圖 7. MRI 模態在不同評估設定下的 Dice 平均分數比較。「不含背景」(0.8073 ± 0.0253)與「含背景」(0.8268 ± 0.0201)之間差異未達統計顯著，Welch 改良式獨立樣本 t 檢定結果為 $t(7.61) = -1.348$, $p = 0.216$, 95% CI $[-0.0531, 0.0141]$ 。誤差棒表示標準差，顯著性以 ns 標示。

在 CT 模態中，不含背景的五次分數為 0.6803、0.6682、0.6089、0.6659 與 0.6445；

含背景則為 0.6915、0.6728、0.7182、0.6641 與 0.7106 (圖 8)。經計算，不含背景的平均值為 0.6536 ($SD=0.0281$)，含背景的平均值為 0.6914 ($SD=0.0233$)。以 Welch 改良式獨立樣本 t 檢定分析，結果為 $t(7.74)=-2.319$ ， $p=0.050$ ，95% CI $[-0.0758, 0.0000]$ ，顯示兩組差異臨界顯著 (圖 9)。




圖 8. CT 模態在不同評估設定下的五次 Dice 分數比較。折線圖顯示「不含背景」(實線)與「含背景」(虛線)於五次隨機抽取測試中的分數變化。雖然兩者在數值上均呈現波動，但整體趨勢顯示含背景分數普遍較高，反映背景納入對 CT 分割效能的影響。




圖 9. CT 模態在不同評估設定下的 Dice 平均分數比較。「不含背景」(0.6536 ± 0.0281)與「含背景」(0.6914 ± 0.0233)之間的差異達臨界顯著，Welch 改良式獨立樣本 t 檢定結果為 $t(7.74)=-2.319$ ， $p=0.050$ ，95% CI $[-0.0758, 0.0000]$ 。誤差棒表示標準差，顯著性以 * 標示。

整體而言，結果符合研究假設 H2，顯示在移除背景後，平均 Dice 分數雖有下降，但能更真實反映模型在器官與病灶等困難類別上的分割效能。在 MRI 模態中，含與不含背景的差異未達顯著 ($t(7.61)=-1.348$ ， $p=0.216$)，顯示其在不同評估規則下的結果相對穩定。然而，在 CT 模態中，差異達臨界顯著 ($t(7.74)=-2.319$ ， $p=0.050$)，顯示背景區域的處理方式對評估結果影響更為敏感。由於 CT 影像的背景佔比龐大且分類相對容易，將背景納入計算會造成整體分數膨脹，進而高估模型效能。相較之下，不含背景的 Dice 更能揭示模型在細微結構與低對比區域的實際表現，因而在跨模態與跨資料集的比較中具備更高的解釋力與公允性；含背景的結果則可作為補充資訊，提供對整體

效能的另一層觀察。

第四章 討論

醫學影像分割的臨床應用不僅依賴演算法的進步，也深受前處理策略與評估規則影響。本研究透過在 MRI 與 CT 上的實驗，聚焦於推論方式（sliding-window 與整圖裁補）及評估設定（含背景與不含背景），驗證這些因素如何改變模型效能的呈現與解讀。

在推論策略比較（RQ1/H1）中，結果顯示 sliding-window 在 MRI 與 CT 中均顯著優於整圖裁補，且差異在 CT 模態最為明顯（ $p < 0.001$ ）。這與既有研究一致，說明切塊式推論能有效減少邊界效應並保留細節（Isensee et al., 2021）。由於 CT 影像軟組織對比度有限，若直接採用整圖推論，容易出現小結構與病灶邊界的模糊，導致 Dice 分數顯著下降。相對地，MRI 具備較佳的軟組織對比，即便在整圖推論下仍能維持一定水準，但 sliding-window 依然展現穩定優勢。此結果凸顯推論方式不只是技術選項，而是影響分割可靠度的關鍵因素。

評估設定比較（RQ2/H2）中，MRI 的「含背景」與「不含背景」分數差異未達顯著，顯示背景納入與否對效能解讀影響有限；但 CT 的差異達臨界顯著（ $p = 0.050$ ）。由於 CT 影像背景佔比龐大且分類相對容易，將其納入會使整體分數膨脹，掩蓋了器官與病灶等困難類別的實際表現。這說明在不同評估規則下，效能指標可能呈現出截然不同的解讀結果；若忽略這一點，容易高估模型能力並影響跨研究比較的公允性。相對而言，排除背景後的 Dice 更能聚焦於臨床真正關注的結構與病灶，提供較具解釋力的效能評估。

整體而言，本研究的發現呼應了研究動機中所提出的挑戰，即便是如 SwinUNETR 這樣的先進模型，其效能仍受到推論與評估設定的高度影響。換言之，前處理策略與評估規範若未嚴謹制定，不僅會影響分割結果的可信度，也可能導致臨床應用上的誤導。因此，本研究不僅驗證了前處理在提升分割可靠性中的重要性，也提供了實務上的建議：未來在跨模態或跨機構研究中，應重視推論與評估的一致性，才能建立更穩健的比較基準。

本研究仍存在若干限制。首先，MRI 與 CT 影像分別來自不同資料集，無法逐一配對比較，因此研究僅在各自模態內進行實驗，而非跨模態配對分析，這限制了結果在模態間直接比較的解釋力。其次，本研究僅聚焦於 SwinUNETR 架構與 Dice 作為單一效能指標，其他模型與多樣化評估指標未被納入，可能影響結論的普遍性。此外，實驗樣本雖經隨機抽取，但樣本量與來源範圍仍有限，未來研究可擴大資料集規模，並結合多中心資料，以提升結果的代表性與外部效度。

第五章 未來展望

後續研究可從多模態資料與方法面兩方面進一步延伸。資料上，建構具跨模態配對的 MRI 與 CT 資料庫，有助於更精確檢驗不同推論與評估設定的效應；方法上，未來可比較其他深度學習架構並結合多元指標，以獲得更全面的效能評估。特別是在 CT 等低對比度影像情境，探討更合適的前處理與推論流程，將有助於提升模型的魯棒性。最

終，若能建立跨機構的一致性規範並融入臨床需求，將有助於縮短研究成果與實務應用間的落差。

參考文獻

- Çiçek, Ö., Abdulkadir, A., Lienkamp, S. S., Brox, T., & Ronneberger, O. (2016). 3D U-Net: Learning dense volumetric segmentation from sparse annotation. *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2016*, 424–432. Springer, Cham. https://doi.org/10.1007/978-3-319-46723-8_49
- Guan, H., & Liu, M. (2022). Domain Adaptation for Medical Image Analysis: A Survey. *IEEE transactions on bio-medical engineering*, 69(3), 1173–1185. <https://doi.org/10.1109/TBME.2021.3117407>
- Hatamizadeh, A., Nath, V., Tang, Y., Yang, D., Roth, H.R., Xu, D. (2022). Swin UNETR: Swin Transformers for Semantic Segmentation of Brain Tumors in MRI Images. In: Crimi, A., Bakas, S. (eds) *Brainlesion: Glioma, Multiple Sclerosis, Stroke and Traumatic Brain Injuries*. BrainLes 2021. Lecture Notes in Computer Science, vol 12962. Springer, Cham. https://doi.org/10.1007/978-3-031-08999-2_22
- Isensee, F., Jaeger, P. F., Kohl, S. A. A., Petersen, J., & Maier-Hein, K. H. (2021). nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation. *Nature methods*, 18(2), 203–211. <https://doi.org/10.1038/s41592-020-01008-z>
- Johns Hopkins Medicine. (n.d.). MRI vs. CT scans. Retrieved from <https://www.hopkinsmedicine.org>
- MD Anderson Cancer Center. (2023). MRI vs. CT: What's the difference? Retrieved from <https://www.mdanderson.org>
- Nyúl, L. G., & Udupa, J. K. (1999). On standardizing the MR image intensity scale. *Magnetic resonance in medicine*, 42(6), 1072–1081. [https://doi.org/10.1002/\(sici\)1522-2594\(199912\)42:6<1072::aid-mrm11>3.0.co;2-m](https://doi.org/10.1002/(sici)1522-2594(199912)42:6<1072::aid-mrm11>3.0.co;2-m)
- Radiopaedia. (2025). CT vs MRI. Retrieved from <https://radiopaedia.org>
- Sudre, C.H., Li, W., Vercauteren, T., Ourselin, S., Jorge Cardoso, M. (2017). Generalised Dice Overlap as a Deep Learning Loss Function for Highly Unbalanced Segmentations. In: Cardoso, M., et al. *Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support . DLMIA ML-CDS 2017* 2017. Lecture Notes in Computer Science(), vol 10553. Springer, Cham. https://doi.org/10.1007/978-3-319-67558-9_28
- WELCH B. L. (1947). The generalisation of student's problems when several different population variances are involved. *Biometrika*, 34(1-2), 28–35. <https://doi.org/10.1093/biomet/34.1-2.28>
- Satterthwaite, F. E. (1946). An approximate distribution of estimates of variance components. *Biometrics*, 2(6), 110–114. <https://doi.org/10.2307/3002019>
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning: With applications in R* (2nd ed.). Springer. <https://doi.org/10.1007/978-1-0716-1418-1>
- Zhou, X., Li, Y., Wang, H., & Zhang, Y. (2024). Challenges and solutions in multimodal medical

image analysis: A review. *Medical Image Analysis*, 89, 102917.
<https://doi.org/10.1016/j.media.2023.102917>

Sudirman, S., Al Kafri, A., Natalia, F., Meidia, H., Afriliana, N., Al-Rashdan, W., Bashtawi, M., & Al-Jumaily, M. (2019). Label image ground truth data for lumbar spine MRI dataset (Version 2) [Data set]. Mendeley Data. <https://doi.org/10.17632/zbf6b4pttk.2>

Kaggle. (n.d.). Spine segmentation from CT scans [Data set]. Kaggle. Retrieved September 25, 2025, from <https://www.kaggle.com/datasets/pycadmk/spine-segmentation-from-ct-scans>